

---

# 第三章 自适应滤波引言

- 线性滤波
- 最优滤波
- 自适应滤波
- 自适应滤波应用举例
- 维纳滤波
- 卡尔曼滤波

---

## 3.2 维纳滤波

## 3.2 维纳滤波

### 一 维纳滤波问题

$y(n)$ ----期望输出(参考信号),  $x(n)$ -----输入信号,  $e(n)$ -----误差信号

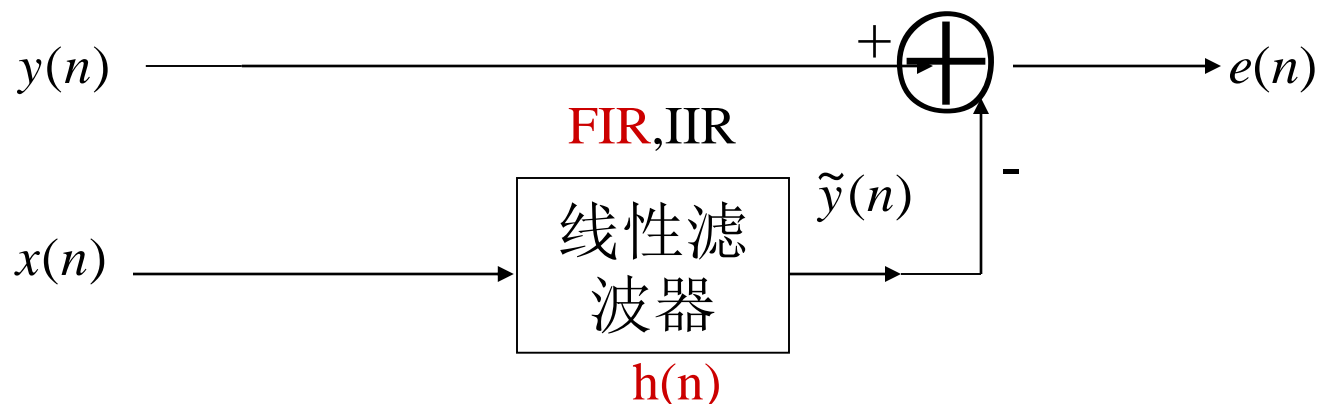
已知条件:  $y(n)$ ,  $x(n)$  是均值为0的平稳离散时间信号, 二阶矩 (自相关, 互相关) 已知. 滤波器是线性的(FIR, IIR)

采用准则: 最小均方误差(MMSE, Minimum Mean-Squared Error)

$$J = E[e^2(n)] = E\{[(y(n) - \tilde{y}(n))]^2\} = \min$$

设计滤波器[求 $h(n)$ ]使在最小均方误差意义下是最优滤波.

-----维纳滤波问题



## 3.2 维纳滤波

$$J = E[e^2(n)] = \min$$

### 二 Wiener-Hopf 方程

$$e(n) = y(n) - \tilde{y}(n) = y(n) - \sum_i h_i x(n-i)$$

设滤波器单位取样响应 $h(n) \rightarrow h_n$ 是实数:

$$\tilde{y}(n) = \sum_i h(i)x(n-i) = \sum_i h_i x(n-i)$$

$$\frac{\partial J}{\partial h_j} = 2E[e(n) \frac{\partial e(n)}{\partial h_j}] = -2E[e(n)x(n-j)] = 0, \forall j, n$$

$$\therefore E[e(n)x(n-j)] = 0, \forall j, n$$

$$E[y(n)x(n-j) - \sum_i h_i x(n-i)x(n-j)] = 0$$


定义:  $r_c(j) = E[y(n)x(n-j)]$

$$r(j) = E[x(n)x(n-j)]$$

则:  $r_c(j) = \sum_i h_i r(j-i), \forall j \quad \longrightarrow \quad \text{Wiener-Hopf 方程}$

## 3.2 维纳滤波

### 三 正交原理(Principle of orthogonality)



正交原理:线性最优滤波(维纳滤波)的充要条件是滤波器的输出(参考信号即期望信号的估计)与误差(估计与参考信号的差)正交.

而:  $e(n) = y(n) - \tilde{y}(n) \Rightarrow y(n) = \tilde{y}(n) + e(n), \forall n$

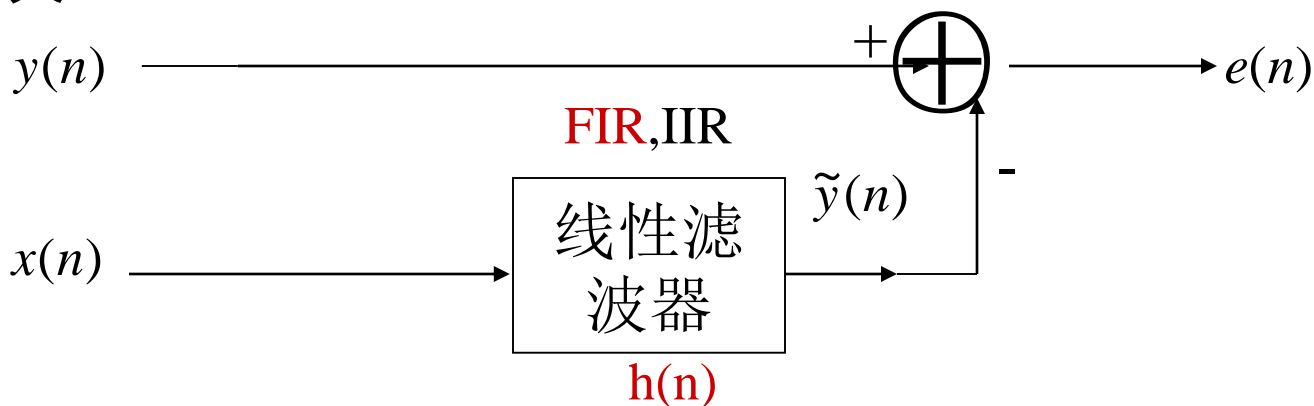
$\tilde{y}(n) = \sum_i h_i x(n-i)$   $\leftarrow \tilde{y}$  是输入信号空间的一个矢量

推论1:线性最优滤波(维纳滤波)的最优估计是参考信号即期望信号在输入信号空间的正交投影.

$$y(n) = \tilde{y}(n) + e(n), \forall n$$

$$E[e(n)\tilde{y}(n)] = 0, \forall n$$

推论2:线性最优滤波(维纳滤波)等价于将参考信号分解为两个正交分量(误差信号分量和滤波器输出信号分量), 误差信号分量与输入信号(正交)不相关, 滤波器输出的信号分量与输入信号(不正交)相关.



## 3.2 维纳滤波

四 N阶FIR维纳滤波器的解,  $0 \leq i \leq N-1$

$$\tilde{y}(n) = \sum_{i=0}^{N-1} h_i x(n-i) \quad \xleftarrow{\text{FIR}} \quad \tilde{y}(n) = \sum_i h_i x(n-i)$$

输入:  $\mathbf{X}(n) = [x(n), x(n-1), \dots, x(n-N+1)]^T$

系数:  $\mathbf{H} = [h_0, h_1, \dots, h_{N-1}]^T$

输出:  $\tilde{y}(n) = \mathbf{H}^T \mathbf{X}(n) = \mathbf{X}^T(n) \mathbf{H}$

$$E[e(n)x(n-j)] = 0; 0 \leq j \leq N-1, \forall n \Rightarrow E[e(n)\mathbf{X}(n)] = 0; \forall n$$

$$\begin{aligned} & E\{[y(n) - \mathbf{H}^T \mathbf{X}(n)]\mathbf{X}(n)\} \\ &= E[y(n)\mathbf{X}(n)] - \underbrace{E[\mathbf{X}(n)\mathbf{X}^T(n)]}_{\mathbf{R}_{xx}} \mathbf{H} = 0 \\ \therefore \mathbf{H}_{opt} &= \mathbf{R}_{xx}^{-1} \mathbf{r}_{yx} \\ &\quad \Longrightarrow O(N^2) \end{aligned}$$

## 3.2 维纳滤波

其中:

$$\mathbf{R}_{xx} = \begin{bmatrix} r(0) & r(1) & \dots & r(N-1) \\ r(1) & r(0) & \dots & r(N-2) \\ \cdot & \cdot & \dots & \cdot \\ \cdot & \cdot & \dots & \cdot \\ r(N-1) & r(N-2) & \dots & r(0) \end{bmatrix}$$

$$r(p) = E[x(n)x(n-p)]$$

$$\mathbf{r}_{yx} = \begin{bmatrix} r_c(0) \\ r_c(1) \\ \vdots \\ r_c(N-1) \end{bmatrix}$$

$\mathbf{R}_{xx}^T = \mathbf{R}_{xx}$  (对称), 且具有 *Toplitz* 性质

$$r_c(p) = E[y(n)x(n-p)]$$



## 3.2 维纳滤波

五 N阶FIR维纳滤波器的最小均方误差  $J_{\min}$

$$J = E[e^2(n)] = E\{[(y(n) - \tilde{y}(n))]^2\}$$

$$\tilde{y}(n) = \mathbf{H}^T \mathbf{X}(n) = \mathbf{X}^T(n) \mathbf{H}$$

$$J = E[y^2(n)] - 2E[y(n)\mathbf{H}^T \mathbf{X}(n)] + E[\mathbf{H}^T \mathbf{X}(n)\mathbf{X}^T(n)\mathbf{H}]$$

$$= E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H}$$

$$J_{\min} = E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H}_{opt} + \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt}$$

$$= E[y^2(n)] - \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt}$$

$$= E[y^2(n)] - \mathbf{H}_{opt}^T \mathbf{r}_{yx}$$

$$* E[y(n)\mathbf{X}^T(n)] = \mathbf{r}_{yx}^T = \mathbf{H}_{opt}^T \mathbf{R}_{xx} \iff \mathbf{H}_{opt} = \mathbf{R}_{xx}^{-1} \mathbf{r}_{yx}$$

## 3.2 维纳滤波

### 六 N阶FIR维纳滤波器的误差性能曲面 (Error-Performance Surface)

$$J(\mathbf{H}) = E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} \quad \text{二次曲面}$$



误差性能曲面 (Error-Performance Surface)

$$J(\mathbf{H}) - J_{\min} = E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} - \\ \{ E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H}_{opt} + \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt} \}$$


$$J(\mathbf{H}) = J_{\min} + (\mathbf{H} - \mathbf{H}_{opt})^T \mathbf{R}_{xx} (\mathbf{H} - \mathbf{H}_{opt})$$



误差性能曲面 (Error-Performance Surface)

$$\mathbf{r}_{yx} = \mathbf{R}_{xx} \mathbf{H}_{opt}; \mathbf{r}_{yx}^T = \mathbf{H}_{opt}^T \mathbf{R}_{xx}$$

$$\begin{aligned}
 J(\mathbf{H}) - J_{\min} &= E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} - \\
 &\quad \{E[y^2(n)] - 2\mathbf{r}_{yx}^T \mathbf{H}_{opt} + \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt}\} \\
 &= -2\mathbf{r}_{yx}^T \mathbf{H} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} + 2\mathbf{r}_{yx}^T \mathbf{H}_{opt} - \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt} \\
 J(\mathbf{H}) - J_{\min} &= -\mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H} - \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H}_{opt} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} + \\
 &\quad 2\mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt} - \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt} \\
 &= -\mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H} - \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H}_{opt} + \mathbf{H}^T \mathbf{R}_{xx} \mathbf{H} + \mathbf{H}_{opt}^T \mathbf{R}_{xx} \mathbf{H}_{opt} \\
 &\quad \Downarrow \\
 J(\mathbf{H}) &= J_{\min} + (\mathbf{H} - \mathbf{H}_{opt})^T \mathbf{R}_{xx} (\mathbf{H} - \mathbf{H}_{opt})
 \end{aligned}$$




结论：N阶FIR维纳滤波器有解且有唯一解

误差性能曲面（Error-performance surface）

## 3.2 维纳滤波

$$E[e(n)x(n-j)] = 0, \forall j, n$$

七 维纳滤波是去相关滤波



$$y(n) = e(n) + \tilde{y}(n)$$


$$= e(n) + \mathbf{H}_{opt}^T \mathbf{X}(n)$$

由正交原理： $e(n)$ 是 $y(n)$ 中和 $\mathbf{X}(n)$ 不相关的部分；

但 $\tilde{y}(n)$ 是 $y(n)$ 中和 $\mathbf{X}(n)$ 相关的部分；

结论： $e(n)$ 作为输出时的维纳滤波（**最优线性滤波**），则是从 $y(n)$ 中移掉和输入 $X(n)$ 相关的部分 $\tilde{y}(n)$ ，输出 $y(n)$ 中和输入 $X(n)$ 不相关的部分

## 自适应谱线增强(Adaptive line Enhancer)



## 3.2 维纳滤波

### 八 维纳滤波和一般线性滤波的比较

Weiner-Hopf方程:  $r_c(j) = \sum_i h_i r(j-i), \forall j$

$x(n) = y(n) + v(n)$   $v(n)$ : noise 和  $y(n)$  不相关


$$r_c(j) = r_{yx}(j) = r_{y(y+v)}(j) = r_{yy}(j);$$

$$r_{xx}(j) = r_{(y+v)(y+v)}(j) = r_{yy}(j) + r_{vv}(j)$$

$$r_c(j) = \sum_i h_i r(j-i), \forall j$$

$$S_{yy}(z) = H(z)[S_{yy}(z) + S_{vv}(z)]$$

$$H(z) = \frac{S_{yy}(z)}{S_{yy}(z) + S_{vv}(z)} \Rightarrow |H(e^{j\omega})| = \frac{|S_{yy}(e^{j\omega})|}{|S_{yy}(e^{j\omega}) + S_{vv}(e^{j\omega})|}$$



## 3.2 维纳滤波

### 九 Examples

#### Example 1: Echo cancellation

$$r_c(j) = \sum_i h_i r(j-i), \forall j$$


$$S_{yx}(z) = H(z)S_{xx}(z)$$

$$y(n) = \tilde{x}(n) + s(n)$$

$$r_c(j) = r_{yx}(j) = r_{(\tilde{x}+s)x}(j) = r_{\tilde{x}x}(j);$$

$$r_{\tilde{x}x}(j) = \sum_i \hat{h}(i) r(j-i) \iff \tilde{x}(n) = \sum_i \hat{h}(i) x(n-i)$$

$$\hat{H}(z)S_{xx}(z) = H(z)S_{xx}(z) \Rightarrow H(z) = \hat{H}(z)$$



在维纳滤波的情况下,  $e(n)$  是  $s(n)$  的 MMSE 估计



## Example 2: inverse modeling problem

$$r_c(j) = \sum_i h_i r(j-i), \forall j$$

$$S_{yx}(z) = H(z) S_{xx}(z)$$

$$x(n) = \hat{d}(n) + v(n) = h_r(n) * d(n) + v(n)$$

$$y(n) = d(n)$$

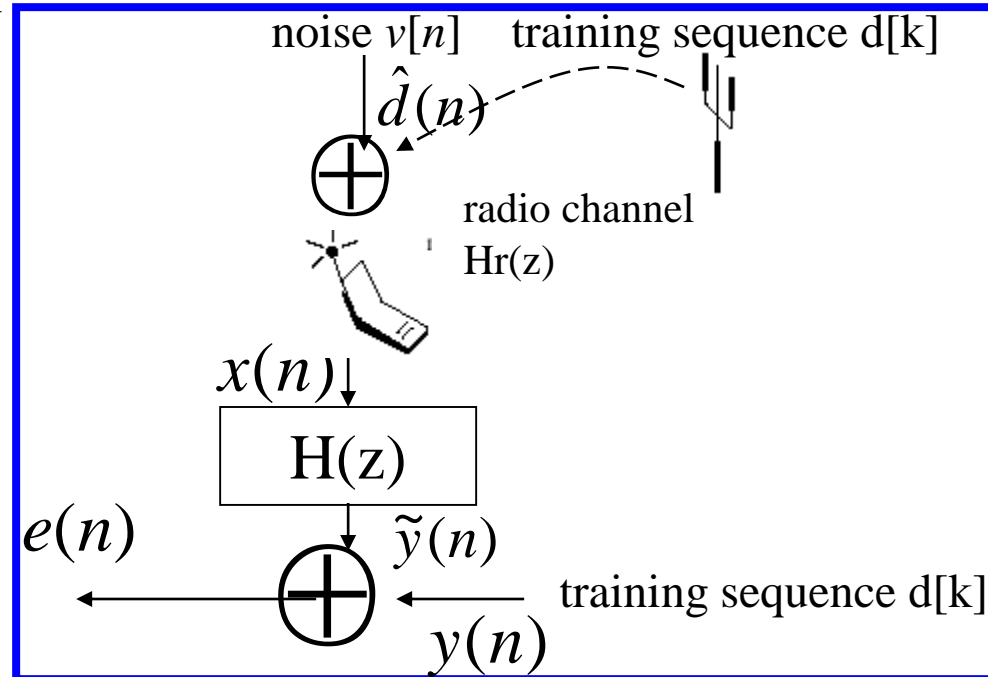
$$r_{yx}(j) = r_{d(h_r * d + v)}(j) = r_{d(h_r * d)}(j)$$

$$S_{yx}(z) = H_r(z^{-1}) S_{dd}(z)$$

$$r_{xx}(j) = r_{(h_r * d + v)(h_r * d + v)}(j) = r_{(h_r * d)(h_r * d)}(j) + r_{vv}(j)$$

$$S_{xx}(z) = H_r(z) H_r(z^{-1}) S_{dd}(z) + S_{vv}(z)$$

$$H(z) = \frac{H_r(z^{-1}) S_{dd}(z)}{H_r(z) H_r(z^{-1}) S_{dd}(z) + S_{vv}(z)} \xrightarrow{S_{vv}(z)=0} H(z) = \frac{1}{H_r(z)}$$



## Example 2: inverse modeling problem

---

$$S_{yx}(z) = H_r(z^{-1})S_{dd}(z)$$



$$r_{yx}(p) = E[y(n)x(n-p)] \quad r_{xx}(p) = E[x(n)x(n-p)]$$

$$\begin{aligned} r_{d(h_r*d)}(p) &= E[d(n) \sum_k h_r(k) d(n-p-k)] \\ &= \sum_k h_r(k) E[d(n) d(n-p-k)] \\ &= \sum_k h_r(k) r_{dd}(p+k) \end{aligned}$$

---

## 3.3 卡尔曼滤波(标量)

### 3.3 卡尔曼滤波

#### 一 问题的提出

在最小均方误差准则下,维纳滤波是一种最优线性滤波,但其要求信号平稳,且由于不是递推算法,计算效率不高.

设:(1)观察信号  $x(1), x(2), \dots, x(n)$ ;

(2)由 $n-1$ 时刻及此前的观察信号,  $x(1), x(2), \dots, x(n-1)$ , 按最小均方误差准则得到 $y(n-1)$ 的最优估计,记为:

$$\tilde{y}(n-1|n-1)$$

问题:当得到新的观察信号 $x(n)$ ,估计:  $\tilde{y}(n|n)$

途径:1)根据  $x(1), x(2), \dots, x(n)$  , 估计  $\tilde{y}(n|n)$  ;(Weiner Filter)

2)叠代的方法:  $\tilde{y}(n-1|n-1) \longrightarrow \tilde{y}(n|n)$

↑  
 $x(n)$

### 3.3 卡尔曼滤波

#### 二 解决方法:

##### (1) 一步预测(One-step prediction)

由  $x(1), x(2), \dots, x(n-1) \longrightarrow x(n) \quad \tilde{x}(n|n-1)$

预测误差:  $\alpha(n) = x(n) - \tilde{x}(n|n-1) \leftarrow$  新息(Innovation)

$x(n)$ 中无法预测的信息,  
或 $x(n)$ 所提供的新的信息

若真实信号 $y(n)$ 具有信号模型:

$$y(n) = ay(n-1) + w(n) \quad \text{状态方程}$$

而观察信号 $x(n)$ 是通过如下测量模型获得:

$$x(n) = cy(n) + v(n) \quad \text{测量方程}$$

### 3.3 卡尔曼滤波

其中 $a, c$ 是绝对值小于1的常数,  $w(n), v(n)$ 是方差分别为 $Q$ 和 $R$ 的白噪音. 且 $v(n)$ 和 $y(n), w(n)$ 不相关. 则新息的计算可分为:

(a) 由已有估计  $\tilde{y}(n-1|n-1)$  通过状态方程对 $y(n)$ 做一步预测:

$$\tilde{y}(n|n-1) = a\tilde{y}(n-1|n-1) \quad \Longleftarrow \quad y(n) = ay(n-1) + w(n)$$

(b) 根据测量方程, 对测量值 $x(n)$ 作一步预测

$$\tilde{x}(n|n-1) = c\tilde{y}(n|n-1) = ca\tilde{y}(n-1|n-1) \quad \Longleftarrow \quad x(n) = cy(n) + v(n)$$

(c)  $x(n)$ 到来后, 计算新息

$$\alpha(n) = x(n) - c\tilde{y}(n|n-1) = x(n) - ca\tilde{y}(n-1|n-1)$$

(2) 根据新息, 对预测值  $\tilde{y}(n|n-1)$  进行修正, 从而得到估计值:

$$\tilde{y}(n|n)$$

$$\tilde{y}(n|n) = \tilde{y}(n|n-1) + G_n \alpha(n)$$

### 3.3 卡尔曼滤波

其中 $G_n$ 是加权因子(预测增益),  $G_n$ 的选取应使根据新息修正所得到的估计  $\tilde{y}(n|n)$  最佳,即使当前时刻的估计和真实值均方误差最小:

$$J(n) = E[e^2(n)] = E[(y(n) - \tilde{y}(n|n))^2] = \min$$

$$\frac{\partial J(n)}{\partial G_n} = 2E[e(n) \frac{\partial e(n)}{\partial G_n}] = 0$$

$$\frac{\partial e(n)}{\partial G_n} = -\alpha(n) \quad \downarrow \quad \tilde{y}(n|n) = \tilde{y}(n|n-1) + G_n \alpha(n)$$

$$E[e(n)\alpha(n)] = 0 \quad \text{or} \quad E\{e(n)[x(n) - c\tilde{y}(n|n-1)]\} = 0$$

$$\tilde{y}(n|n) = \tilde{y}(n|n-1) + G_n \alpha(n)$$

$$\alpha(n) = x(n) - c\tilde{y}(n|n-1) = x(n) - ca\tilde{y}(n-1|n-1)$$

(1) 求  $G_n$

$$E[e(n)\alpha(n)] = 0 \quad \text{or} \quad E\{e(n)[x(n) - c\tilde{y}(n|n-1)]\} = 0$$

令:  $e_1(n) = y(n) - \tilde{y}(n|n-1)$  (调整前误差, 一步预测误差)

$p(n) = E[e_1^2(n)]$  (一步预测误差功率)

$e(n) = y(n) - \tilde{y}(n|n)$  (调整后误差)

$$= y(n) - \tilde{y}(n|n-1) - G_n[x(n) - c\tilde{y}(n|n-1)]$$

$$= e_1(n) - G_n[cy(n) + v(n) - c\tilde{y}(n|n-1)]$$

$$= (1 - cG_n)e_1(n) - G_nv(n)$$

$$\alpha(n) = x(n) - c\tilde{y}(n|n-1)$$

$$= cy(n) + v(n) - c\tilde{y}(n|n-1)$$

$$= ce_1(n) + v(n)$$

测量方程

$$x(n) = cy(n) + v(n)$$



$$E[e(n)\alpha(n)] = E\{[(1 - cG_n)e_1(n) - G_nv(n)][ce_1(n) + v(n)]\}$$

$$= c(1 - cG_n)p(n) - G_nR \quad v(n) \text{ 和 } e_1(n) \text{ 不相关}$$

$$= 0$$

$$G_n = \frac{cp(n)}{R + c^2 p(n)}$$

$$= \frac{c}{R/p(n) + c^2} \quad [p(n) \uparrow \Rightarrow G_n \uparrow]$$

## (2)求J(n)

最优线性滤波,由正交原理:

$$E[e(n)\tilde{y}(n|n)] = 0$$

同时:  $E[e(n)\alpha(n)] = 0$

$$\tilde{y}(n|n) = \tilde{y}(n|n-1) + G_n \alpha(n)$$

$$\begin{aligned} 0 &= E[e(n)\tilde{y}(n|n)] = E[e(n)\tilde{y}(n|n-1) + e(n)G_n \alpha(n)] \\ &= E[e(n)\tilde{y}(n|n-1)] \end{aligned}$$

$$E[e(n)\tilde{y}(n|n-1)] = 0$$

$$E[e(n)\alpha(n)] = 0$$

$$E[e(n)x(n)] = 0$$

$$\alpha(n) = x(n) - c\tilde{y}(n|n-1) \quad \left. \begin{array}{l} E[e(n)\tilde{y}(n|n-1)] = 0 \\ E[e(n)\alpha(n)] = 0 \end{array} \right\} \begin{array}{l} E[e(n)x(n)] = 0 \\ + \\ x(n) = cy(n) + v(n) \end{array}$$

$$E[e(n)y(n)] = -\frac{1}{c} E[e(n)v(n)]$$



$$J(n) = E[e^2(n)] = E[e(n)(y(n) - \tilde{y}(n|n))]$$

$$= E[e(n)y(n)]$$

$$E[e(n)y(n)] = -\frac{1}{c} E[e(n)v(n)]$$

$$= -\frac{1}{c} E[e(n)v(n)]$$

$$e(n) = (1 - cG_n)e_1(n) - G_nv(n) \quad v(n) \text{ 和 } e_1(n) \text{ 不相关}$$

$$J(n) = \frac{1}{c} G_n R$$

$$G_n = \frac{cp(n)}{R + c^2 p(n)} \Rightarrow G_n R = cp(n)[1 - cG_n]$$

$$J(n) = [1 - cG_n]p(n)$$

---

(3)求 $p(n)$

$$p(n) = E[e_1^2(n)] = E\{[y(n) - \tilde{y}(n|n-1)]^2\}$$

$$= E\{[y(n) - a\tilde{y}(n-1|n-1)]^2\}$$

$$= E\{[ay(n-1) + w(n) - a\tilde{y}(n-1|n-1)]^2\}$$

$$= E\{[ae(n-1) + w(n)]^2\}$$

$$e(n) = y(n) - \tilde{y}(n|n)$$

$$= a^2 E[e^2(n-1)] + E[w^2(n)]$$

$w(n)$ 和 $e(n-1)$ 不相关

$$= a^2 J(n-1) + Q$$

### 3.3 卡尔曼滤波

---

(4) 综合:

$$\tilde{y}(n|n) = a\tilde{y}(n-1|n-1) + G_n[x(n) - ca\tilde{y}(n-1|n-1)]$$

$$p(n) = a^2 J(n-1) + Q$$

$$G_n = \frac{cp(n)}{R + c^2 p(n)}$$

$$J(n) = \frac{R}{C} G_n = (1 - cG_n) p(n)$$

初始条件:  $\tilde{y}(0|0), J(0)$

### 3.3 卡尔曼滤波

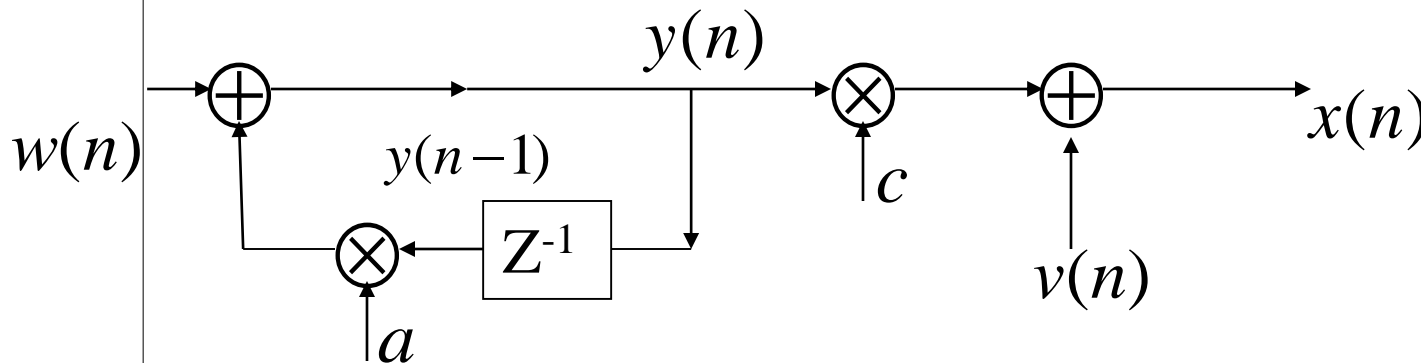
#### 三 Summary of Kalman Filter

已知真实信号 $y(n)$ 具有信号模型:

$$y(n) = ay(n-1) + w(n) \quad \text{状态方程}$$

及观察信号 $x(n)$ 的测量模型:

$$x(n) = cy(n) + v(n) \quad \text{测量方程}$$



由 $n$ 时刻及此前的观察信号  $x(1), x(2), \dots, x(n)$   
估计 $n$ 时刻的真实信号 $y(n)$

### 3.3 卡尔曼滤波

#### 基于一步预测的Kalman Filter

$$\tilde{y}(n|n) = a\tilde{y}(n-1|n-1) + G_n[x(n) - ca\tilde{y}(n-1|n-1)]$$

$$p(n) = a^2 J(n-1) + Q$$

$$G_n = \frac{cp(n)}{R + c^2 p(n)}$$

$$J(n) = \frac{R}{C} G_n = (1 - cG_n) p(n)$$

